

SIG-LOG

Sistema Integral de Gestión Logística

UNIDAD II · PREPARACIÓN DE LOS DATOS

Ingeniería en Desarrollo y Gestión de Software

Asignatura: Extracción del conocimiento en bases de datos

Alumna: Sofia Sanchez Duran

Periodo: Mayo – Agosto 2026

Proyecto integrador

De archivos dispersos a información lista para analizar



Resultado: datos consistentes, relacionados y preparados para indicadores, modelos y visualizaciones

Documento técnico-académico de preparación, integración y almacenamiento de datos

1. Propósito de la unidad

La Unidad II convierte las fuentes identificadas en la Unidad I en información utilizable para el análisis. En SIG-LOG esta etapa es crítica porque los resultados posteriores —indicadores, modelos predictivos, agrupaciones y visualizaciones— dependen de que los datos tengan estructuras, tipos, relaciones y valores consistentes.

Principio de calidad

Un modelo no corrige automáticamente un dato mal preparado. La limpieza y transformación forman parte del conocimiento que se obtiene del proyecto.

2. Fuentes y tipos de datos

El proyecto trabaja con información logística distribuida en archivos correspondientes a las principales entidades del caso. Para el análisis se consideran datos estructurados, ya que se organizan en registros y campos con una estructura definida.

Fuente / entidad	Contenido esperado	Uso en el análisis
Clientes	Identificación y características del cliente	Relacionar demanda y entregas
Vehículos	Identificación, tipo y características	Costos, consumo, desempeño y mantenimiento
Operadores	Identificación y participación	Carga operativa y desempeño
Rutas	Origen, destino y características	Frecuencia, distancia y retrasos
Entregas	Fechas, tiempos, estatus, costos y operación	Indicadores y modelos
Componentes	Piezas y componentes asociados al mantenimiento	Análisis de fallas
Mantenimiento	Tipo, componente, causa, severidad, costo y horas fuera de servicio	Riesgo y prevención

3. Identificación de problemas de calidad

Antes de cargar la información al entorno analítico deben revisarse problemas que puedan alterar resultados. La preparación debe considerar, como mínimo:

- Valores faltantes o incompletos.

- Tipos de datos incorrectos, especialmente fechas y cantidades numéricas.
- Registros duplicados.
- Nombres o categorías escritas de formas diferentes.
- Relaciones entre entidades que no puedan resolverse.
- Valores atípicos que requieran revisión.
- Unidades o formatos inconsistentes.
- Registros que no cumplan las reglas del negocio.

Importante para SIG-LOG


La limpieza no debe eliminar información únicamente porque parezca diferente. Cada corrección debe tener una razón y, cuando sea posible, conservarse la trazabilidad entre el dato original y el dato utilizado para análisis.

4. Proceso ETL aplicado

El proceso ETL organiza la preparación en tres grandes actividades: extracción, transformación y carga. En SIG-LOG estas actividades permiten pasar de archivos operativos a una estructura analítica que puede ser consultada de forma consistente.

Etapa	Qué se realiza	Resultado
Extracción	Lectura de las fuentes y selección de los campos necesarios	Datos disponibles para procesar
Transformación	Limpieza, normalización, conversión de tipos, creación de variables y relaciones	Datos consistentes y preparados
Carga	Inserción de la información transformada en el almacén analítico	Datos disponibles para consultas y análisis

De archivos dispersos a información lista para analizar



Resultado: datos consistentes, relacionados y preparados para indicadores, modelos y visualizaciones

Figura 1. Flujo conceptual de preparación y carga de datos de SIG-LOG. Elaboración propia.

5. Limpieza y transformación

5.1 Normalización de formatos

Las fechas, cantidades, costos, distancias, tiempos y categorías deben almacenarse en formatos homogéneos. Esto permite agrupar por mes, comparar periodos, calcular promedios y utilizar las variables en modelos.

5.2 Integridad entre entidades

Las entidades deben poder relacionarse mediante identificadores. Por ejemplo, una entrega debe poder asociarse con una ruta, un vehículo y un operador; un registro de mantenimiento debe poder asociarse con el vehículo y el componente involucrado.

5.3 Variables derivadas

Cuando una pregunta de negocio requiere una medida que no existe directamente, puede construirse una variable derivada. Ejemplos: duración de una entrega, indicador de entrega tardía, porcentaje de retrasos, costo por distancia o proporción de fallas por componente.

Regla de interpretación

Una variable derivada debe documentarse: nombre, fórmula, unidad, fuente y finalidad. Esto permite explicar al profesor y a otro desarrollador exactamente cómo se obtuvo.

6. Data Warehouse

El Data Warehouse concentra la información preparada para consultas analíticas. Su finalidad dentro de SIG-LOG es separar el uso analítico de la organización original de los archivos operativos y facilitar consultas consistentes.

Organización analítica propuesta para SIG-LOG




Figura 2. Representación conceptual de la organización analítica de SIG-LOG.

6.1 Modelo estrella

Para explicar el análisis logístico, una estructura de tipo estrella resulta apropiada porque permite mantener una tabla central de hechos —por ejemplo, las entregas— relacionada con dimensiones como vehículo, ruta, operador y cliente.

6.2 Ventajas para el proyecto

- Consultas analíticas más claras.
- Facilidad para agrupar por tiempo, vehículo, ruta u operador.
- Base común para el dashboard.
- Menor dependencia de la estructura de los archivos originales.
- Posibilidad de comparar indicadores con criterios consistentes.

7. Validaciones antes del análisis

Validación	Pregunta	Ejemplo de resultado	Acción si falla
------------	----------	----------------------	-----------------

Compleitud	¿Faltan valores importantes?	Porcentaje de registros incompletos	Revisar fuente o aplicar tratamiento documentado
Unicidad	¿Existen duplicados?	Registros repetidos	Investigar y resolver
Consistencia	¿Las categorías tienen el mismo formato?	Nombres equivalentes escritos distinto	Normalizar
Integridad referencial	¿Las relaciones existen?	Entrega sin vehículo relacionado	Corregir o marcar incidencia
Rango	¿Los valores son plausibles?	Costo o distancia fuera de rango	Revisar dato y regla de negocio

8. Relación con mantenimiento

La preparación de datos es especialmente importante en mantenimiento. Para que una falla pueda convertirse en una alerta o recomendación, debe conservarse la relación entre vehículo, componente, causa, severidad, costo y horas fuera de servicio.

Por ejemplo, si existen registros de una misma pieza que falla repetidamente, el análisis posterior puede cuantificar su frecuencia y costo. Esa evidencia puede utilizarse para priorizar inspecciones, disponibilidad de refacciones o mantenimiento preventivo.

Ejemplo de conocimiento accionable

No basta con decir “hay fallas”. Un análisis útil debe poder llegar a: qué componente falla, en qué vehículo, con qué frecuencia, por qué causa, qué severidad presenta, cuánto cuesta y cuánto tiempo deja al vehículo fuera de servicio.

9. Relación con las siguientes unidades

Unidad	Dependencia
III. Análisis supervisado	Utiliza variables preparadas para entrenar y evaluar modelos de predicción.
IV. Análisis no supervisado	Requiere variables consistentes para descubrir grupos y estructuras.
V. Presentación y visualización	Consume los datos preparados para construir indicadores y gráficas interpretables.

10. Resultado de aprendizaje de la Unidad II

El resultado esperado es contar con un conjunto de datos preprocesado y una estructura analítica que permitan continuar con seguridad hacia los modelos y visualizaciones. La evidencia debe permitir identificar las fuentes, transformaciones, reglas de limpieza y organización del Data Warehouse.

11. Evidencias que debe conservar el proyecto

- Archivos originales y archivos limpios.
- Código de limpieza y transformación.
- Scripts de carga al Data Warehouse.
- Base de datos analítica.
- Consultas utilizadas para comprobar integridad y resultados.
- Descripción de variables y transformaciones.
- Resultados de validación de calidad.
- Repositorio con los componentes necesarios para reproducir el proceso.

12. Conclusiones

- La preparación de datos es una etapa fundamental porque determina la confiabilidad de los análisis posteriores.
- SIG-LOG requiere integrar varias entidades para responder preguntas de negocio que no pueden resolverse desde un solo archivo.
- El proceso ETL permite convertir fuentes operativas en información estructurada para análisis.
- El Data Warehouse proporciona una base común para consultas, modelos y visualizaciones.
- En mantenimiento, conservar el detalle del componente y la causa de falla aumenta el valor preventivo del sistema.