

SIG-LOG

Sistema Integral de Gestión Logística

UNIDAD III · ANÁLISIS SUPERVISADO

Predicción, evaluación y optimización de modelos

Ingeniería en Desarrollo y Gestión de Software

Asignatura: Extracción del conocimiento en bases de datos

Alumna: Sofía Sanchez Duran

Periodo: Mayo – Agosto 2026

Proyecto integrador: SIG-LOG

Documento: Entregable académico ampliado para demostrar la aplicación de la Unidad III al caso de transporte y distribución. Los valores numéricos de desempeño deben coincidir con los reportes generados por el entrenamiento; no se inventan métricas en este documento.

1. Propósito de la Unidad III

La Unidad III corresponde al análisis supervisado: una etapa en la que el sistema aprende a partir de ejemplos históricos que ya contienen un resultado conocido. En SIG-LOG, esta capacidad se utiliza para convertir los registros operativos en predicciones que puedan apoyar decisiones concretas.

Objetivos principales:

- Definir el problema y la variable a predecir.
- Preparar y documentar las variables.
- Separar datos en entrenamiento y prueba.
- Entrenar distintos modelos y medir su desempeño.
- Optimizar la alternativa seleccionada.
- Traducir los resultados en acciones logísticas concretas.

Elemento	Aplicación en SIG-LOG
Caso de clasificación	Predecir si una entrega tiene riesgo de llegar tarde.
Caso de regresión	Estimar una variable numérica de la operación a partir de las variables disponibles en el conjunto de entrenamiento.
Datos de entrada	Información de entregas, rutas, vehículos y demás variables disponibles después del proceso ETL.
Resultado	Una predicción que debe acompañarse de una medida de confianza/desempeño y de una interpretación operativa.
Uso empresarial	Priorizar revisiones, prevenir retrasos, planificar recursos y apoyar decisiones de operación.

2. Problema de negocio que se busca resolver

Una empresa de transporte necesita anticiparse a los problemas antes de que una entrega se convierta en una incidencia. Un retraso no sólo representa minutos adicionales: puede afectar ventanas de entrega, satisfacción del cliente, utilización del vehículo, combustible y costos operativos.

2.1 Preguntas que responde el análisis

- ¿Qué características de una entrega están asociadas con mayor riesgo de retraso?
- ¿El sistema puede identificar anticipadamente una entrega que probablemente llegue tarde?
- ¿Qué modelo produce predicciones más útiles y confiables para este caso?
- ¿Qué tan grande es el error cuando se predice una variable numérica?
- ¿La optimización del modelo mejora el desempeño respecto de una versión inicial?

- ¿Cómo debe convertirse una predicción en una acción operativa?

2.2 Regla de interpretación

Principio clave: Una predicción no sustituye al responsable de logística. La predicción sirve como señal para priorizar atención. Por ejemplo, una entrega marcada como de alto riesgo puede provocar una revisión de ruta, horario, vehículo o disponibilidad del operador antes de que ocurra el retraso.

3. Datos y variables utilizadas

El Data Warehouse y los procesos de preparación desarrollados en las unidades anteriores constituyen la base del entrenamiento. El repositorio del proyecto contiene, además, preprocesadores y archivos de entrenamiento/prueba, lo que permite reproducir la etapa supervisada.

Fuente/archivo del proyecto	Función dentro del análisis
siglog_dw.db	Fuente integrada para consultas analíticas.
preprocesador_entregas.pkl	Preprocesamiento asociado al conjunto de entregas.
preprocesador_regresion.pkl	Preprocesamiento empleado en el flujo de regresión.
preprocesador_regresion_optimizado.pkl	Versión utilizada en el flujo optimizado de regresión.
X_train.pkl / y_train.pkl	Datos de entrenamiento y variable objetivo.
X_test.pkl / y_test.pkl	Datos reservados para evaluar el comportamiento del modelo.
metadata_entrenamiento.json	Metadatos del proceso de entrenamiento.
nombres_variables.pkl	Correspondencia de variables utilizada por los modelos.

3.1 Variables del dominio

De acuerdo con el caso de estudio y la estructura analítica del proyecto, las variables pueden representar características de la entrega, ruta, vehículo, combustible, costos, carga, paquetes, tiempos y retrasos. Antes de entrenar, cada variable debe documentarse indicando su significado, tipo, unidad y si puede conocerse antes de que ocurra el resultado.

Variable / grupo	Tipo esperado	Uso en el modelo	Revisión necesaria
Distancia	Numérica	Representa recorrido o magnitud de la ruta.	Verificar unidad y valores extremos.
Carga / paquetes	Numérica	Representa volumen operativo de la entrega.	Evitar negativos y revisar valores atípicos.
Combustible	Numérica	Representa consumo o recurso asociado al recorrido.	Verificar unidad y relación temporal.

Costo	Numérica	Representa costo operativo disponible en el conjunto.	Revisar si el costo se conoce antes de la predicción.
Tiempo / duración	Numérica	Puede explicar dificultad o duración del servicio.	Definir claramente cuándo se mide.
Ruta / vehículo / categorías	Categórica	Representan contexto operativo.	Codificar de forma consistente.
Minutos de retraso / estatus	Objetivo o variable derivada	Permite definir el resultado supervisado.	No usar información futura como entrada.

Punto importante para el profesor: Una variable que sólo se conoce después de terminar la entrega no debe utilizarse como entrada si el objetivo es predecir el retraso antes de que suceda. De lo contrario, el modelo parecería muy preciso porque estaría recibiendo información del futuro.

4. Diseño del aprendizaje supervisado

Flujo de trabajo del análisis supervisado en SIG-LOG




Figura 1. Flujo de trabajo del análisis supervisado aplicado a SIG-LOG. Elaboración propia.

4.1 Separación entrenamiento–prueba

El conjunto de entrenamiento se utiliza para aprender patrones; el conjunto de prueba se mantiene separado para estimar cómo se comportará el modelo ante datos que no utilizó durante el aprendizaje. En el repositorio existen `X_train`, `y_train`, `X_test` y `y_test`, por lo que el documento debe conservar esa separación.

4.2 Preprocesamiento

- Identificar variables numéricas y categóricas.
- Aplicar las transformaciones necesarias mediante los preprocesadores guardados.
- Conservar exactamente el mismo orden y significado de variables entre entrenamiento y predicción.

- Evitar que información del conjunto de prueba influya en el entrenamiento.
- Guardar el preprocesador junto con el modelo para que una futura predicción reciba los datos en el mismo formato.

5. Modelos de regresión y clasificación

El repositorio de SIG-LOG contiene varias alternativas de modelos. La comparación es importante porque no existe un algoritmo que sea automáticamente el mejor para todos los problemas.

Modelo disponible	Tipo	Qué busca aprender	Ventaja para comparar
LinearRegression.pkl	Regresión	Relación numérica entre variables de entrada y una salida.	Sirve como referencia sencilla.
DecisionTreeRegressor.pkl	Regresión	Reglas que dividen los datos para estimar una salida numérica.	Fácil de interpretar y capaz de modelar relaciones no lineales.
RandomForestRegressor.pkl	Regresión	Combina múltiples árboles para estimar una salida.	Suele capturar relaciones más complejas.
RandomForestRegressor_Optimizado.pkl	Regresión	Versión ajustada del bosque para mejorar su desempeño.	Permite demostrar optimización.
LogisticRegression.pkl	Clasificación	Estima la probabilidad de pertenecer a una clase.	Referencia clara para clasificación binaria.
DecisionTree.pkl	Clasificación	Genera reglas de decisión para separar clases.	Permite explicar rutas de decisión.
RandomForest.pkl	Clasificación	Combina varios árboles para clasificar.	Robusto para relaciones complejas.
RandomForest_Optimizado.pkl	Clasificación	Versión ajustada del bosque.	Permite comparar antes/después de optimizar.

5.1 ¿Por qué comparar varios modelos?

Comparar modelos evita elegir una técnica únicamente por popularidad. La selección debe considerar el desempeño medido, la estabilidad, la facilidad de interpretación, el costo computacional y la utilidad para el negocio.

Criterio	Pregunta que debe responder el reporte
Desempeño	¿Qué modelo comete menos errores o clasifica mejor?

Generalización	¿El desempeño se mantiene en datos no utilizados para entrenar?
Interpretabilidad	¿Podemos explicar por qué se genera una predicción?
Operación	¿El modelo puede integrarse al flujo de SIG-LOG?
Mantenimiento	¿Es posible volver a entrenarlo cuando existan nuevos datos?

6. Evaluación de regresión

En regresión se predice una cantidad numérica. La secuencia didáctica solicita reportar Error Absoluto Medio y Error Cuadrático Medio. Ambas métricas deben calcularse sobre datos de evaluación y compararse entre modelos.

6.1 Error Absoluto Medio (MAE)

El MAE representa, en promedio, cuánto se alejan las predicciones del valor real en términos absolutos. Un MAE menor indica menor error promedio.

Fórmula: $MAE = (1/n) \times \sum |\text{valor real} - \text{valor predicho}|$

6.2 Error Cuadrático Medio (MSE)

El MSE eleva al cuadrado cada error antes de promediarlo. Por ello penaliza con mayor fuerza los errores grandes.

Fórmula: $MSE = (1/n) \times \sum (\text{valor real} - \text{valor predicho})^2$




Figura 2. Lectura conceptual de los errores de un modelo de regresión. Elaboración propia.

Resultado observado en el reporte	Interpretación
-----------------------------------	----------------

MAE menor	El modelo se acerca más al valor real, en promedio.
MSE menor	El modelo reduce especialmente los errores grandes.
Mejora después de optimizar	La configuración ajustada aporta evidencia de mejora.
Empeora después de optimizar	La optimización no necesariamente fue beneficiosa; debe conservarse la comparación.

No inventar resultados: En la versión final de entrega, los valores de MAE y MSE deben copiarse directamente de los reportes generados por SIG-LOG. Si una métrica no está calculada en los archivos, debe indicarse como pendiente en lugar de fabricar un número.

7. Evaluación de clasificación

En clasificación, SIG-LOG busca distinguir entre entregas con diferentes resultados, por ejemplo, entregas a tiempo frente a entregas tardías. La evaluación debe explicar no sólo un porcentaje global, sino qué tipo de error está cometiendo el sistema.

Cómo interpretar una matriz de confusión

Resultado observado	Real: a tiempo	Se le escapó un retraso	A tiempo correctamente
	Real: tarde	Detectó tarde correctamente	Falsa alarma
		Predijo a tiempo	Predijo tarde
		Predicción del modelo	

Figura 3. Interpretación operativa de una matriz de confusión. Elaboración propia.

Situación	Significado para logística
-----------	----------------------------

Predijo tarde y realmente se retrasó	Acierto útil: permite priorizar una entrega que efectivamente estaba en riesgo.
Predijo tarde y llegó a tiempo	Falsa alarma: puede provocar una revisión innecesaria.
Predijo a tiempo y se retrasó	Fallo crítico: el sistema no detectó una entrega problemática.
Predijo a tiempo y llegó a tiempo	Acierto correcto.

7.1 Métricas que deben presentarse

Métrica	Qué comunica	Cómo explicarla sin tecnicismos
Accuracy	Proporción total de predicciones correctas.	De cada conjunto de entregas, cuántas fueron clasificadas correctamente.
Precision	Qué tan confiables son las alertas positivas.	Cuando el sistema avisa que una entrega se retrasará, qué tan seguido acierta.
Recall	Capacidad para detectar los casos positivos.	De todas las entregas que realmente se retrasaron, cuántas logró detectar.
F1-score	Equilibrio entre precision y recall.	Resume el equilibrio entre no generar demasiadas falsas alarmas y no dejar retrasos sin detectar.

8. Optimización y selección del modelo

El repositorio contiene versiones optimizadas de modelos de clasificación y regresión. La optimización debe documentarse como un experimento reproducible: qué se modificó, por qué se modificó, qué resultado se obtuvo y si la modificación realmente mejoró el desempeño.

Paso	Evidencia que debe quedar
Modelo base	Nombre exacto del archivo y métricas iniciales.
Parámetros ajustados	Parámetros o configuración utilizada.
Modelo optimizado	Nombre exacto del archivo generado.
Comparación	Tabla antes vs. después.
Decisión	Explicación de por qué se conserva una versión.
Reproducibilidad	Código, preprocesador y archivos necesarios para repetir el experimento.

8.1 Tabla recomendada para la entrega

Modelo	Tipo	Métrica 1	Métrica 2	Optimizado	Decisión
--------	------	-----------	-----------	------------	----------

Linear Regression	Regresión	[valor real]	[valor real]	No	Referencia
Decision Tree Regressor	Regresión	[valor real]	[valor real]	No	Comparar
Random Forest Regressor	Regresión	[valor real]	[valor real]	No	Comparar
Random Forest Regressor Optimizado	Regresión	[valor real]	[valor real]	Sí	Evaluar como candidato
Logistic Regression	Clasificación	[valor real]	[valor real]	No	Referencia
Decision Tree	Clasificación	[valor real]	[valor real]	No	Comparar
Random Forest	Clasificación	[valor real]	[valor real]	No	Comparar
Random Forest Optimizado	Clasificación	[valor real]	[valor real]	Sí	Evaluar como candidato

9. Interpretación de resultados para la toma de decisiones

La extracción de conocimiento no termina cuando aparece una métrica. El valor del modelo está en traducir el resultado a una acción que una persona pueda ejecutar.

Predicción / hallazgo	Acción recomendada	Beneficio esperado
Entrega con alto riesgo de retraso	Revisar ruta, tráfico, ventana de entrega y disponibilidad del vehículo/operador.	Reducir retrasos evitables.
Vehículo asociado repetidamente con incidencias	Revisar historial de mantenimiento y condición del vehículo.	Prevenir fallas y paros.
Ruta con comportamiento desfavorable	Analizar tiempos, distancia, horarios y alternativas.	Mejorar planeación.
Error de predicción elevado	No usar el resultado como decisión automática; revisar variables y calidad de datos.	Evitar decisiones basadas en predicciones poco confiables.
Modelo mejorado después de optimización	Integrarlo como candidato para pruebas controladas.	Aumentar la utilidad analítica.

9.1 Ejemplo de una alerta entendible

Ejemplo de interfaz: “Entrega E-1042 · Riesgo alto de retraso. Revisar ruta y horario de salida.” Debajo de la alerta, el sistema debe permitir consultar las variables que justifican el

análisis y el desempeño histórico del modelo. La redacción final debe evitar mostrar nombres técnicos del algoritmo al usuario operativo.

10. Riesgos y controles del modelo

Riesgo	Qué puede ocurrir	Control propuesto
Fuga de información	El modelo recibe una variable que sólo existe después del resultado.	Revisar cada variable y su momento de disponibilidad.
Datos desbalanceados	Una clase domina y la exactitud parece alta aunque se detecten pocos retrasos.	Revisar matriz de confusión, precisión, recall y F1.
Sobreajuste	El modelo funciona muy bien en entrenamiento pero empeora con datos nuevos.	Evaluar siempre con conjunto de prueba y comparar brechas.
Datos nuevos con otro comportamiento	El modelo pierde desempeño con cambios operativos.	Monitorear métricas y reentrenar periódicamente.
Mala calidad de datos	Predicciones incorrectas por errores en entradas.	Validaciones ETL y reglas de calidad.
Interpretación incorrecta	Una predicción se toma como certeza.	Mostrar que es una estimación y acompañarla de contexto.

11. Integración con SIG-LOG

La etapa supervisada debe conectarse con los módulos operativos y con el dashboard. El usuario final no necesita conocer el código para utilizar una predicción; necesita conocer qué significa y qué puede hacer con ella.

Módulo	Integración con análisis supervisado
Entregas	Mostrar riesgo estimado y permitir revisar el contexto de la entrega.
Rutas	Relacionar desempeño histórico con posibles retrasos.
Vehículos	Cruzar predicciones con historial de costos y mantenimiento.
Operadores	Consultar carga operativa cuando sea una variable válida para el análisis.
Mantenimiento	Usar antecedentes como contexto de riesgo, sin confundir correlación con causalidad.
Reportes y análisis	Presentar comparaciones, métricas y recomendaciones.
Dashboard	Convertir los resultados en indicadores, alertas y tarjetas de decisión.

12. Evidencias que debe contener la entrega

Para cumplir de forma sólida con el resultado de aprendizaje de la unidad, el expediente debe permitir a un tercero comprobar qué se hizo y por qué.

- Documento técnico de la Unidad III.
- Código de entrenamiento y evaluación de regresión y clasificación.
- Dataset o referencia reproducible al conjunto utilizado.
- Archivos de entrenamiento y prueba.
- Preprocesadores utilizados.
- Modelos entrenados y versiones optimizadas.
- Tabla comparativa de modelos.
- Reporte de métricas.
- Descripción de variables y variable objetivo.
- Explicación del caso de uso.
- Interpretación de resultados y decisiones recomendadas.
- Capturas o evidencias de ejecución cuando sean necesarias.

12.1 Checklist de revisión antes de entregar

Verificación	Estado
¿Se explica claramente qué se quiere predecir?	☐
¿La variable objetivo está definida?	☐
¿Se explica qué datos se utilizan?	☐
¿Se distingue regresión de clasificación?	☐
¿Se documenta entrenamiento y prueba?	☐
¿Se comparan varios modelos?	☐
¿Se reportan MAE y MSE para regresión?	☐
¿Se explican los errores de clasificación?	☐
¿Se documenta la optimización?	☐
¿Los números coinciden con los archivos de resultados?	☐
¿Se interpreta el resultado desde el punto de vista logístico?	☐
¿El código y los modelos están incluidos en el repositorio?	☐

13. Relación con la secuencia didáctica

Indicador solicitado en la actividad	Evidencia en SIG-LOG
Algoritmos de aprendizaje supervisado	Regresión lineal, clasificación logística, árboles y Random Forest disponibles en el repositorio.
Evaluación de modelos	Uso de conjunto de prueba y métricas de error/clasificación.
Justificación del algoritmo	Comparación de alternativas y criterio de selección.

Diseño del modelo	Flujo documentado desde datos preparados hasta predicción.
Reporte de evaluación	Tabla de métricas y análisis antes/después de optimizar.
Entrega del modelo	Archivos .pkl, preprocesadores y metadatos del entrenamiento.

14. Conclusión

SIG-LOG aplica el aprendizaje supervisado como una extensión natural del proceso de extracción de conocimiento: primero se preparan datos confiables, después se construyen modelos capaces de aprender patrones y finalmente se evalúa si esos modelos pueden aportar valor a la operación.

La calidad del entregable no debe medirse únicamente por tener archivos .pkl o por mostrar una métrica alta. Un proyecto completo debe explicar el problema, justificar las variables, demostrar una evaluación independiente, comparar alternativas, documentar la optimización y traducir los resultados a decisiones comprensibles para el personal de logística.

Criterio final: La versión definitiva debe incorporar los valores reales de las tablas de comparación y reportes generados por el proyecto. Este documento deja explícitamente marcados los puntos donde no se debe inventar información.