

SIG-LOG

Sistema Integral de Gestión Logística

UNIDAD IV

Análisis no supervisado

Ingeniería en Desarrollo y Gestión de Software

Asignatura: Extracción del conocimiento en bases de datos

Alumna: Sofia Sanchez Duran

Periodo: Mayo – Agosto 2026

Documento técnico-académico de evidencia

Contenido

1. 1. Introducción
2. 2. Objetivo general y objetivos específicos
3. 3. Problema de análisis
4. 4. Contexto y datos utilizados
5. 5. Preparación de los datos
6. 6. Estrategia de análisis no supervisado
7. 7. Segmentación de las entregas
8. 8. Perfil e interpretación de los grupos
9. 9. Evaluación de la agrupación
10. 10. Reducción de dimensionalidad
11. 11. Interpretación de los componentes
12. 12. Integración de resultados con SIG-LOG
13. 13. Apoyo a la toma de decisiones
14. 14. Limitaciones y control de calidad
15. 15. Evidencias y archivos generados
16. 16. Conclusiones
17. 17. Referencias técnicas del proyecto

Nota de trazabilidad

Este documento utiliza los resultados y estructura del proyecto SIG-LOG disponibles en la evidencia proporcionada. Los resultados numéricos de agrupación y reducción de dimensionalidad deben conservar exactamente los valores generados por los archivos entregas_clusters.csv, perfil_clusters.csv, evaluacion_kmeans.csv, varianza_pca.csv, cargas_componentes.csv, entregas_pca.csv e interpretacion_componentes.csv. No se inventan métricas de calidad ni porcentajes de componentes cuando esos archivos no están disponibles en el material consultado.

1. Introducción

Propósito de la unidad

Descubrir grupos y patrones de comportamiento dentro de las entregas de SIG-LOG sin depender de una variable objetivo, y reducir la complejidad de las variables para facilitar su interpretación operativa.

La Unidad IV del proyecto SIG-LOG corresponde al análisis no supervisado. Su propósito es complementar los análisis descriptivos y predictivos desarrollados en otras etapas mediante técnicas capaces de encontrar estructuras dentro de los datos sin definir previamente una categoría objetivo.

En el contexto logístico, esta perspectiva resulta útil porque no todas las situaciones importantes están predefinidas. Dos entregas pueden compartir características de distancia, costo, carga o retraso aunque pertenezcan a rutas diferentes. Identificar esos comportamientos permite construir perfiles operativos y posteriormente relacionarlos con rutas, vehículos, costos, combustible, mantenimiento y desempeño.

La unidad utiliza dos líneas de análisis: la segmentación de entregas mediante agrupación y la reducción de dimensionalidad para facilitar la representación e interpretación de múltiples variables.

2. Objetivo general y objetivos específicos

Aplicar técnicas de aprendizaje no supervisado al conjunto de datos de SIG-LOG para identificar grupos de entregas con características similares y reducir la complejidad de las variables utilizadas en el análisis, con el propósito de descubrir patrones que contribuyan a la toma de decisiones logísticas.

2.1 Objetivos específicos

- Preparar las variables necesarias para el análisis no supervisado.
- Identificar grupos de entregas con comportamientos semejantes.
- Describir cuantitativamente las características de cada grupo.
- Evaluar la calidad de la agrupación mediante las métricas generadas por el proyecto.
- Reducir la complejidad de las variables mediante componentes que faciliten su visualización.
- Interpretar qué variables contribuyen en mayor medida a los patrones encontrados.
- Relacionar los resultados con situaciones reales de operación logística.
- Generar recomendaciones que puedan utilizarse dentro de SIG-LOG para apoyar decisiones.

3. Problema de análisis

SIG-LOG concentra información de clientes, vehículos, operadores, rutas, entregas, combustible y mantenimiento. Los análisis descriptivos permiten conocer totales, promedios y tendencias, pero no necesariamente muestran si existen diferentes perfiles de operación dentro del conjunto de entregas.

Pregunta central

¿Existen grupos de entregas que presenten comportamientos suficientemente similares como para tratarlos como perfiles operativos diferentes?

4. Contexto y datos utilizados

El conjunto de datos de SIG-LOG fue construido para representar la operación de una empresa de transporte y distribución. La evidencia del proyecto registra 100 clientes, 40 vehículos, 60 operadores, 50 rutas, 20 componentes y 5,000 entregas. El periodo de generación de entregas abarca del 1 de enero al 15 de agosto de 2026.

Conjunto	Registros	Función dentro del proyecto
Clientes	100	Identificación de los destinatarios y demanda de servicio.
Vehículos	40	Información de la flota y características operativas.
Operadores	60	Seguimiento del personal que realiza las entregas.
Rutas	50	Características de origen, destino, distancia y tráfico.
Componentes	20	Catálogo de elementos asociados al mantenimiento.
Entregas	5,000	Base principal para el análisis operativo y de patrones.

La generación del dataset utiliza una semilla fija de 42 para reproducibilidad. Las entregas incorporan variables como peso de carga, cantidad de paquetes, distancia real, combustible consumido, costos, minutos de retraso, estatus y observaciones.

La evidencia también muestra que 3,515 entregas fueron realizadas a tiempo y 1,485 fueron tardías, equivalentes a 29.70 % del total. El retraso promedio general fue de 12.66 minutos y el retraso promedio entre las entregas tardías fue de 42.62 minutos.

Indicador general	Valor
Registros analizados	5,000 entregas
Entregas a tiempo	3,515
Entregas tardías	1,485
Porcentaje de retrasos	29.70 %
Retraso promedio general	12.66 min
Retraso promedio de entregas tardías	42.62 min
Retraso máximo	103 min
Distancia recorrida	1,379,691.48 km
Combustible consumido	179,079.80 L
Costo total de operación	\$17,231,289.39
Costo promedio por entrega	\$3,446.26

5. Preparación de los datos

Antes de aplicar técnicas no supervisadas, las variables deben encontrarse en condiciones adecuadas para el análisis. En el procesamiento de SIG-LOG se realizan conversiones de tipos de datos para variables booleanas, numéricas y fechas.

Entre las variables numéricas utilizadas en el análisis general del proyecto se encuentran minutos de retraso, distancia real en kilómetros, combustible consumido, precio del combustible, costo de envío, costo de combustible y costo total.

Variable	Tipo funcional	Interpretación
minutos_retraso	Númerica	Tiempo de desviación respecto a la entrega programada.
distancia_real_km	Númerica	Distancia recorrida durante la entrega.
combustible_consumido_litros	Númerica	Combustible utilizado en la operación.
precio_combustible	Númerica	Precio por litro utilizado en el cálculo.
costo_envio	Númerica	Costo asociado al servicio de entrega.
costo_combustible	Númerica	Costo del combustible utilizado.
costo_total	Númerica	Costo total asociado a la operación.
entrega_tardia	Booleana	Indica si la entrega presentó retraso.

Control de calidad

La evidencia de análisis del dataset reporta cero valores nulos y cero registros duplicados en los seis conjuntos revisados. Esto proporciona una base consistente para continuar con la transformación y modelado.

6. Estrategia de análisis no supervisado

El análisis se divide en dos procesos complementarios. Primero se realiza una agrupación de entregas para descubrir perfiles de comportamiento. Después se aplica reducción de dimensionalidad para representar conjuntos de variables de forma más sencilla.

Etapas	Pregunta que responde	Resultado esperado
Preparación	¿Los datos están listos para analizarse?	Variables consistentes y utilizables.
Agrupación	¿Qué entregas se parecen entre sí?	Asignación de grupos y perfiles.

Evaluación	¿Qué tan consistente es la separación?	Métricas de calidad.
Reducción	¿Cómo representar muchas variables con menos dimensiones?	Componentes y representación transformada.
Interpretación	¿Qué significa cada patrón?	Lectura operativa y recomendaciones.

7. Segmentación de las entregas

El proyecto genera el archivo entregas_clusters.csv, que contiene las entregas con el grupo asignado, y perfil_clusters.csv, que permite describir las características promedio de cada grupo.

La segmentación no debe interpretarse como una clasificación de 'buenas' o 'malas' entregas. Un grupo es un conjunto de registros que comparte características según las variables utilizadas durante el proceso. La interpretación empresarial se realiza posteriormente a partir de los valores observados.

7.1 Cómo debe presentarse cada grupo

Dato a presentar	Qué permite conocer
Número de entregas	Tamaño absoluto del grupo.
Porcentaje del total	Peso del grupo dentro de la operación.
Promedio de distancia	Magnitud típica del desplazamiento.
Promedio de costo	Costo característico del perfil.
Promedio de retraso	Comportamiento temporal del grupo.
Combustible	Consumo asociado al perfil, si la variable está incluida.
Otras variables	Características que realmente diferencian al grupo.

Regla de interpretación

Los nombres de los grupos deben derivarse de los resultados reales. Por ejemplo, un nombre como 'operaciones de alta distancia' solamente es válido si el perfil correspondiente presenta una distancia claramente superior respecto a los demás grupos.

7.2 Tabla de perfil para la entrega final

Grupo	Entregas	%	Distancia promedio	Costo promedio	Retraso promedio	Interpretación
Grupo 1	Consultar perfil_clusters.csv	Calcular	Consultar archivo	Consultar archivo	Consultar archivo	Derivar de las variables predominantes.
Grupo 2	Consultar perfil_clusters.csv	Calcular	Consultar archivo	Consultar archivo	Consultar archivo	Derivar de las variables predominantes.
Grupo 3	Consultar perfil_clusters.csv	Calcular	Consultar archivo	Consultar archivo	Consultar archivo	Derivar de las variables predominantes.

8. Perfil e interpretación de los grupos

La interpretación debe ir más allá de indicar que existen grupos. Para cada grupo se debe responder qué lo caracteriza, qué tan grande es, qué comportamiento presenta y qué decisión podría apoyarse con esa información.

8.1 Plantilla de interpretación aplicada

Perfil de operación

El grupo representa [X] % de las entregas. Sus características principales son [variables y valores reales]. En comparación con los demás grupos, presenta [mayor/menor] comportamiento en [variable]. Esto permite interpretarlo como [nombre comprensible para negocio], siempre que la evidencia del perfil lo sustente.

8.2 Traducción de resultados técnicos a lenguaje de negocio

Etiqueta técnica	Forma recomendada de presentarla
Cluster	Grupo o perfil de entregas
Centroide	Comportamiento promedio del grupo
PCA	Reducción de variables / representación de patrones
Componente principal	Dimensión que resume varias características
Carga	Peso o contribución de una variable al componente
Silhouette	Medida de qué tan bien separados están los grupos

9. Evaluación de la agrupación

La evaluación de la agrupación se realiza mediante las métricas contenidas en `evaluacion_kmeans.csv`. Estas métricas deben presentarse con su valor real y una interpretación breve.

Métrica	Valor del proyecto	Interpretación
Métrica 1	Consultar <code>evaluacion_kmeans.csv</code>	Explicar qué indica respecto a la separación de los grupos.
Métrica 2	Consultar <code>evaluacion_kmeans.csv</code>	Explicar qué indica respecto a la cohesión o separación.
Métrica 3	Consultar <code>evaluacion_kmeans.csv</code>	Explicar únicamente si aparece en el archivo.

Criterio académico

No se debe afirmar que una cantidad de grupos es 'óptima' solamente porque el algoritmo la produjo. La conclusión debe sustentarse con las métricas de evaluación realmente generadas.

10. Reducción de dimensionalidad

El proyecto también incorpora resultados de reducción de dimensionalidad. La finalidad es representar la información mediante un número menor de dimensiones, conservando una proporción importante de la variabilidad presente en las variables originales.

Los archivos de evidencia son `varianza_pca.csv`, `cargas_componentes.csv`, `entregas_pca.csv` e `interpretacion_componentes.csv`.

10.1 Varianza explicada

La varianza explicada permite conocer cuánta información queda representada por cada componente y, de manera acumulada, cuánto del comportamiento original puede representarse mediante un número reducido de dimensiones.

Componente	Varianza explicada	Varianza acumulada	Interpretación
Componente 1	Consultar <code>varianza_pca.csv</code>	Consultar archivo	Describir según resultado real.
Componente 2	Consultar <code>varianza_pca.csv</code>	Consultar archivo	Describir según resultado real.
Componente 3	Consultar <code>varianza_pca.csv</code>	Consultar archivo	Describir según resultado real.
Componente 4	Consultar <code>varianza_pca.csv</code>	Consultar archivo	Describir según resultado real.

11. Interpretación de los componentes

Las cargas de los componentes permiten conocer qué variables contribuyen con mayor peso a cada dimensión. Esta información es necesaria para transformar una representación matemática en una explicación comprensible.

Componente	Variables con mayor contribución	Significado empresarial
Componente 1	Consultar cargas_componentes.csv	Nombrar el patrón únicamente a partir de las variables dominantes.
Componente 2	Consultar cargas_componentes.csv	Nombrar el patrón únicamente a partir de las variables dominantes.
Componente 3	Consultar cargas_componentes.csv	Nombrar el patrón únicamente a partir de las variables dominantes.
Componente 4	Consultar cargas_componentes.csv	Nombrar el patrón únicamente a partir de las variables dominantes.

11.1 Representación visual

Las gráficas de la carpeta graficas/pca deben incorporarse como evidencia del proceso. En el documento final, cada figura debe incluir título descriptivo, ejes con unidades, leyenda cuando corresponda y una interpretación de dos niveles: qué se observa y qué implica para SIG-LOG.

Ejemplo de redacción correcta

En lugar de titular una figura únicamente como 'PC1 vs PC2', se recomienda utilizar un título orientado a la interpretación, por ejemplo: 'Distribución de las entregas según sus principales características operativas'. Debajo se debe indicar qué variables explican los ejes y qué comportamiento destaca.

12. Integración de resultados con SIG-LOG

El valor del análisis no supervisado aumenta cuando sus resultados se relacionan con los módulos restantes del sistema. La segmentación de entregas puede cruzarse con rutas, vehículos, operadores y mantenimiento para encontrar explicaciones y generar acciones.

Resultado observado	Cruce recomendado	Posible uso
Perfil con alto costo	Vehículos + rutas + combustible	Revisar asignación y costo operativo.
Perfil con mayor retraso	Rutas + horarios + causas	Priorizar análisis de causas de retraso.
Perfil con alta distancia	Rutas + vehículos	Revisar planeación y asignación.
Perfil con alto consumo	Vehículos + combustible	Detectar operaciones que requieren revisión.
Perfil de comportamiento eficiente	Rutas + vehículos + operadores	Usarlo como referencia comparativa.

13. Apoyo a la toma de decisiones

La salida esperada de la Unidad IV no es únicamente una tabla de grupos. El objetivo es convertir los patrones en acciones concretas, manteniendo siempre la trazabilidad entre dato, interpretación y decisión.

Hallazgo	Decisión sugerida	Acción dentro de SIG-LOG
Grupo con costos elevados	Revisar eficiencia económica	Mostrar vehículos, rutas y combustible relacionados.
Grupo con retrasos elevados	Priorizar prevención	Consultar causas históricas y rutas involucradas.
Grupo con alta distancia	Optimizar planeación	Comparar rutas y vehículos asignados.
Grupo con consumo elevado	Revisar uso de combustible	Consultar rendimiento y costo por vehículo.
Grupo estable/eficiente	Tomarlo como referencia	Comparar otros perfiles contra este comportamiento.

Importante

Estas acciones son líneas de decisión y no afirmaciones de que un grupo concreto tenga ese comportamiento. La versión final debe sustituir cada condición por el hallazgo real obtenido de `perfil_clusters.csv` y `entregas_clusters.csv`.

14. Limitaciones y control de calidad

La interpretación de modelos no supervisados depende de las variables seleccionadas, su escala, la preparación previa y la calidad de los datos. Por ello, un grupo encontrado

matemáticamente no debe interpretarse como una categoría empresarial definitiva sin revisar sus características.

- No asignar nombres de negocio a los grupos sin revisar primero su perfil real.
- No afirmar que una cantidad de grupos es óptima sin revisar las métricas de evaluación.
- No interpretar un componente únicamente por su nombre; debe revisarse la contribución de sus variables.
- Mantener los mismos archivos de resultados que alimentan el dashboard para garantizar trazabilidad.
- Si se modifican los datos o el preprocesamiento, volver a generar los resultados antes de actualizar el documento.

15. Evidencias y archivos generados

Ruta / archivo	Evidencia
no_supervisado/resultados/entregas_cluster_s.csv	Asignación de las entregas a los grupos.
no_supervisado/resultados/perfil_clusters.csv	Características y estadísticas de los grupos.
no_supervisado/resultados/evaluacion_kmeans.csv	Métricas de evaluación de la agrupación.
pca/resultados/varianza_pca.csv	Varianza explicada y acumulada.
pca/resultados/cargas_componentes.csv	Contribución de variables a los componentes.
pca/resultados/entregas_pca.csv	Representación transformada de las entregas.
pca/resultados/interpretacion_componentes.csv	Apoyo para interpretar los componentes.
graficas/pca/	Evidencia visual de la reducción de dimensionalidad.
dashboard/dashboard.py	Presentación interactiva de resultados dentro de SIG-LOG.

15.1 Evidencia que debe aparecer en el documento final

- Tabla de tamaño y porcentaje de cada grupo.
- Perfil cuantitativo de cada grupo.
- Gráfica de distribución de grupos.
- Tabla y gráfica de evaluación.
- Gráfica de varianza explicada y acumulada.
- Tabla de variables con mayor contribución.
- Visualizaciones de los principales componentes.
- Interpretación empresarial de los patrones.
- Recomendaciones de decisión asociadas a los hallazgos.

16. Conclusiones

La Unidad IV incorpora al proyecto SIG-LOG una perspectiva de descubrimiento de conocimiento que complementa los análisis descriptivos y predictivos. En lugar de partir de una respuesta previamente definida, el análisis no supervisado permite explorar si existen estructuras y perfiles de comportamiento dentro de las entregas.

La agrupación de entregas permite organizar registros con características semejantes y posteriormente describir qué variables distinguen cada perfil. La evaluación permite comprobar la calidad de la separación obtenida, mientras que la reducción de dimensionalidad facilita la representación de múltiples variables y su interpretación.

Desde el punto de vista empresarial, el mayor valor de esta unidad se obtiene cuando los grupos y componentes se relacionan con las demás fuentes del sistema. De esta manera, un patrón puede convertirse en una señal para revisar rutas, vehículos, combustible, retrasos o mantenimiento.

Conclusión integradora

SIG-LOG no utiliza el análisis no supervisado únicamente para mostrar un algoritmo. Lo utiliza como una etapa de descubrimiento que transforma comportamientos similares en perfiles analizables y que posteriormente pueden convertirse en criterios de seguimiento y apoyo a la toma de decisiones.

17. Referencias técnicas del proyecto

Las referencias de esta unidad corresponden principalmente a los propios artefactos del proyecto SIG-LOG y a la documentación técnica de las bibliotecas empleadas durante su implementación.

- Archivos de datos y resultados generados por SIG-LOG.
- Scripts de procesamiento y análisis del proyecto.
- Documentación técnica de Python y las bibliotecas utilizadas en el proyecto.
- Material didáctico de la asignatura Extracción del conocimiento en bases de datos.

SIG-LOG · Unidad IV · Análisis no supervisado

Documento preparado para integración en la entrega final del proyecto